
Relatório de Sprint – Projeto mrDBA

1. Identificação do Projeto

Projeto: mrDBA – Pipeline sobre Gerenciamento de DBs

Disciplina: Projeto Supervisionado em Engenharia de Dados

Aluno: Marcelo Araújo e Breno

Sprint: Sprint 3 – Pipeline de Dados (Staging - Curated - DW)

Data: Março de 2026

2. Objetivo da Sprint

Implementar o pipeline de transformação e carga de dados do projeto **mrDBA**, contemplando:

- Processamento de dados da camada **staging** → **curated**
 - Enriquecimento dos dados (cliente, servidor, tempo de resolução)
 - Criação do **Data Warehouse (DW)** no PostgreSQL
 - Implementação da carga incremental
 - Execução automatizada via script de pipeline
 - Registro de logs de execução
-

3. Arquitetura do Ambiente

A arquitetura foi atualizada com os seguintes componentes:

```
|— README.md
|— dashboard
|   |— powerbi
|— data_lake
|   |— curated
|       |— tickets
|           |— mrdba_tickets_curated_2026_01.csv
|   |— raw
|       |— tickets
|           |— mrdba_tickets_2026_01.json
|   |— staging
|       |— tickets
|           |— mrdba_tickets_staging_2026_01.csv
|— docker
|   |— docker-compose.yml
|— docs
|   |— diagramas
|   |— evidencias
|   |— relatorios
|— logs
|   |— pipeline.log
|— requirements.txt
|— scripts
|   |— ingestao
|       |— extrair_tickets_mes.py
|   |— transformacao
|       |— json_to_staging.py
|       |— staging_to_curated.py
|   |— carga
|   |— load_dw.py
|   |— pipeline
|       |— run_pipeline.py
|   |— monitoramento
|       |— logger.py
|— sql
|   |— ddl
|   |— dml
|   |— views
```

4. Etapas Implementadas

3.1 Transformação (Staging → Curated)

- Extração de:
 - **cliente** a partir do *subject*
 - **servidor**
- Padronização de colunas
- Conversão de datas
- Cálculo de tempo_resolucao_horas

3.2 Modelagem DW

Criação de uma tabela fato temporária para testes de carga:

dw.fato_tickets

Campos:

- id_ticket
- data_abertura
- data_fechamento
- cliente
- status
- prioridade
- tempo_resolucao_horas

3.3 Carga no DW

- Conexão com PostgreSQL via SQLAlchemy
- Estratégia:
 - carga incremental por mês
 - remoção prévia dos dados do período
- Inserção via pandas.to_sql

3.4 Pipeline automatizado

Script:

run_pipeline.py

Executa:

1. JSON → STAGING
2. STAGING → CURATED
3. CURATED → DW

3.5 Logging

- Criação automática da pasta `/logs`
- Registro de:
 - sucesso
 - erro
 - tempo de execução

4. Evidências

4.1 Ingestão de tickets

```
(venv) marcelo@kubuntu:/dados/projetos/mrdba/scripts/ingestao$ python extrair_tickets_mes_v2.py 2026 02
=====
EXTRAÇÃO DE TICKETS - FRESHDESK
=====
Domínio: mrdba-help.freshdesk.com
Mês solicitado: 2026-02
Arquivo de saída: /dados/projetos/mrdba/data_lake/raw/tickets/mrdba_tickets_2026_02.json
=====

Janela: 2026-02-01 até 2026-02-08 (fim exclusivo)
Query: created_at:>'2026-01-31' AND created_at:<'2026-02-08'
Página 1: 30 retornados | 30 novos | acumulado: 30
Página 2: 30 retornados | 30 novos | acumulado: 60
Página 3: 30 retornados | 30 novos | acumulado: 90
Página 4: 28 retornados | 28 novos | acumulado: 118
Página 5: sem resultados

Janela: 2026-02-08 até 2026-02-15 (fim exclusivo)
Query: created_at:>'2026-02-07' AND created_at:<'2026-02-15'
Página 1: 30 retornados | 30 novos | acumulado: 148
Página 2: 30 retornados | 30 novos | acumulado: 178
Página 3: 30 retornados | 30 novos | acumulado: 208
Página 4: 30 retornados | 30 novos | acumulado: 238
Página 5: 2 retornados | 2 novos | acumulado: 240
Página 6: sem resultados

Janela: 2026-02-15 até 2026-02-22 (fim exclusivo)
Query: created_at:>'2026-02-14' AND created_at:<'2026-02-22'
Página 1: 30 retornados | 30 novos | acumulado: 270
Página 2: 9 retornados | 9 novos | acumulado: 279
Página 3: sem resultados

Janela: 2026-02-22 até 2026-03-01 (fim exclusivo)
Query: created_at:>'2026-02-21' AND created_at:<'2026-03-01'
Página 1: 30 retornados | 30 novos | acumulado: 309
Página 2: 30 retornados | 30 novos | acumulado: 339
Página 3: 30 retornados | 30 novos | acumulado: 369
Página 4: 30 retornados | 30 novos | acumulado: 399
Página 5: 1 retornados | 1 novos | acumulado: 400
Página 6: sem resultados

=====
EXTRAÇÃO CONCLUÍDA
Total de tickets extraídos: 400
JSON salvo em: /dados/projetos/mrdba/data_lake/raw/tickets/mrdba_tickets_2026_02.json
=====
```

4.2 Execução do staging → curated

```
(venv) marcelo@kubuntu:/dados/projetos/mrdba/scripts/transformacao$ python json_to_staging.py 2026 02
STAGING criado
(venv) marcelo@kubuntu:/dados/projetos/mrdba/scripts/transformacao$ python staging_to_curated_v3.py 2026 02
📄 Lendo arquivo: /dados/projetos/mrdba/data_lake/staging/tickets/mrdba_tickets_staging_2026_02.csv
📋 Colunas encontradas: ['id', 'subject', 'status', 'priority', 'type', 'created_at', 'updated_at', 'custom_fields.cf_sgdb', 'custom_fields.cf_ambiente', 'custom_fields.cf_status']
✅ CURATED gerado com sucesso: /dados/projetos/mrdba/data_lake/curated/tickets/mrdba_tickets_curated_2026_02.csv
📊 Total de registros: 400
```

4.3. Criação da tabela temporária fato_tickets no PostgreSQL

db_mrdba=# \d dw.fato_tickets

Table "dw.fato_tickets"				
Column	Type	Collation	Nullable	Default
ticket_id	bigint			
data_abertura	timestamp without time zone			
status	text			
prioridade	text			
tipo_ticket	text			
sgdb	text			
ambiente	text			
servidor	text			
tempo_resolucao_horas	numeric			
cliente	character varying(255)			

4.4 Execução do load_dw

(venv) marcelo@kubuntu:/dados/projetos/mrdba/scripts/carga\$ python load_dw_v4.py 2026 02

• Prévia dos dados:

ticket_id	data_abertura	status	prioridade	sgdb	ambiente	servidor	tempo_resolucao_horas
0	57640 2026-02-06 12:37:10	Resolvido	Alta	...	Oracle	Produção	NaN 509.216111
1	57639 2026-02-06 11:55:08	Aguardando o cliente	Baixa	...	Sql Server	Produção	0.155556
2	57634 2026-02-06 11:04:33	Aguardando o cliente	Baixa	...	Oracle	Produção	NaN 1.270000
3	57633 2026-02-06 11:00:12	Aguardando o cliente	Baixa	...	Oracle	Produção	NaN 1.659722
4	57632 2026-02-06 10:59:59	Aguardando o cliente	Baixa	...	Sql Server	Produção	NaN 1.085278

[5 rows x 10 columns]

• Tipos das colunas:

ticket_id	int64
data_abertura	datetime64[us]
status	str
prioridade	str
tipo_ticket	str
cliente	str
sgdb	str
ambiente	str
servidor	str
tempo_resolucao_horas	float64

dtype: object

• Valores nulos em data_abertura: 0

✓ Removendo dados do mês (se existirem)...

• Inserindo novos dados...

✓ Carga do mês 2026-02 concluída com sucesso!

4.5 Dados carregados no dw

6 SELECT *

7 FROM dw.fato_tickets

8 WHERE data_abertura >= '2026-02-01'

9 AND data_abertura < '2026-03-01'

10 ORDER BY data_abertura DESC

11 LIMIT 20;

Data Output Messages Notifications

Showing rows: 1 to 20 Page No: 1 of 1

ticketId	data_abertura	status	prioridade	tipo_ticket	sgdb	ambiente	servidor	tempo_resolucao_horas	cliente
1	58530 2026-02-27 11:55:08	Aguardando o cliente	Baixa	Checklist	Sql Server	Produção	EC2AMAZ-KTTVF...	4.658888888888889	NAO IDENTIFICADO
2	58529 2026-02-27 11:04:28	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.0347222222222222	SNCBD001
3	58528 2026-02-27 11:00:09	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.0080555555555555	MILLS
4	58527 2026-02-27 10:59:52	Aguardando o cliente	Baixa	Checklist	Sql Server	Produção	[null]	5.5861111111111111	A NOSSA DROGARIA
5	58523 2026-02-27 10:17:45	Aguardando o cliente	Baixa	Checklist	Sql Server	Produção	SES-SQL-PRD\BI	6.2952777777777778	NAO IDENTIFICADO
6	58522 2026-02-27 10:15:08	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.5377777777777778	MILLS
7	58521 2026-02-27 10:03:48	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.7569444444444444	MILLS
8	58520 2026-02-27 10:00:14	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.7886111111111112	MILLS
9	58519 2026-02-27 10:00:10	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.7933333333333333	MILLS
10	58517 2026-02-27 10:00:03	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.7997222222222222	MILLS
11	58515 2026-02-27 10:00:03	Aguardando o cliente	Baixa	Checklist	Oracle	Produção	[null]	0.7994444444444444	MILLS

4.6 Arquivos de log

```
(venv) marcelo@kubuntu:/dados/projetos/mrdba/logs$ cat pipeline.log
2026-03-18 10:33:24.627251 - SUCESSO - 2026-02
2026-03-18 10:41:50.933947 - SUCESSO - 2026-02
2026-03-18 15:31:52.055470 - SUCESSO - 2026-01
2026-03-25 14:50:04.209621 - SUCESSO - 2026-02
```

5. Resultados da Sprint

- Pipeline funcional end-to-end
- Dados tratados e enriquecidos
- DW estruturado
- Processo automatizado
- Logging implementado

6. Problemas enfrentados

- erro de import
- inconsistência de colunas
- extração de cliente via regex
- erro de autenticação PostgreSQL
- erro de schema (nome das colunas)
- ausência da pasta logs

9. Próximos Passos (Sprint 4)

Na próxima sprint estão previstas as seguintes atividades:

- Criação de dimensões (modelo estrela)
 - Integração com Power BI
 - Orquestração (cron ou Airflow)
 - Melhorias no monitoramento
-